
주택 '고가' 분류 예측 모델

면적 vs. 편의시설, 무엇이 더 결정적인가?

20215235 전승혁

20227122 윤태근

목차

01. 데이터의 출처

02. 데이터 각 변수의 의미

03. 가설 설정

04. 변수 설정 및 의미

05. 데이터 가공 및 계획방법

06. 이상값 결측값 처리방법

07. 모델 활용 방안 및 기대효과

데이터와 선정 이유

- 주택 가격 데이터셋 (Housing Prices Dataset)
- 출처: 캐글(Kaggle)
 - <https://www.kaggle.com/datasets/yasserh/housing-prices-dataset?resource=download>
- 주제 선정 이유
 - "면적이 넓으면 비싸다"는 '당연한 사실' 을 검증하는 것이 아님.
 - ' 선호 지역', '에어컨', '주차공간' 같은 옵션들의 '조합'이 '고가 주택'을 결정짓는 핵심 요인이 될 수 있는지 그 우선순위를 분석

데이터 각 변수의 의미

price	주택 가격
-------	-------

area	주택의 총 면적
bedrooms	침실 수
bathrooms	욕실 수
stories	층수

mainroad	주 도로 접근성
guestroom	게스트룸 유무
basement	지하실 유무
hotwaterheating	온수 난방 유무
airconditioning	에어컨 유무
parking	주차 공간 수
prefarea	선호 지역 여부
furnishingstatus	가구 상태

영가설, 대립가설 설정

- 연구 질문
 - 고가 주택'을 분류하는 데 있어, 전통적인 요인(면적)과 편의시설/환경 요인 중 무엇이 더 결정적인가?
- 영가설 (H0)
 - 주택의 'area(면적)'는 '고가 주택' 분류에 가장 결정적인 영향을 미치며, 편의시설/환경 요인의 영향력은 면적보다 미미하다.
- 대립가설 (H1)
 - area(면적)의 영향력만큼이나, 주요 편의시설/환경 요인의 조합이 '고가 주택' 분류에 결정적인 영향을 미친다.

설명변수, 반응변수 설정 및 의미

- 반응 변수 (Y)
 - price (주택 가격): 숫자형(Numeric)
 - ➡ '고가(1)/저가(0)'의 범주형(Price_Label)으로 가공 예정
- 주요 설명 변수 (X)
 - area (면적),
airconditioning (에어컨 유무), parking (주차 공간 수), prefarea (선호 지역 여부)

데이터 가공 계획 및 방법



- 반응 변수 가공 (price)
 - price의 분포를 확인 후, 중앙값을 기준으로 Price_Label (1: High / 0: Low) 파생 변수 생성
- 설명 변수 가공 (정제)
(변수: mainroad, guestroom, basement, hotwaterheating, airconditioning, prefarea)
 - 현재 'yes' 와 'no' 라는 문자열로 되어 있어, 'yes'는 1로, 'no'는 0으로 변환 예정

데이터 가공 계획 및 방법

- 설명 변수 가공 (인코딩), (변수: furnishingstatus)
 - 'furnished', 'semi-furnished', 'unfurnished' 3가지 상태를 가진 범주형 변수
 - 원-핫 인코딩 (One-Hot Encoding)을 사용하여 furnishing_furnished, furnishing_semi-furnished 같은 가변수 생성 예정.
- 설명 변수 가공 (스케일링)
 - area와 bedrooms 등 값의 범위 차이가 큰 변수 ➡ 표준화 적용

이상값, 결측값 처리 방법

- 결측값 없음(545/545)
- "이상값을 확인했으나, 이는 실제 존재하는 고가/대형 매물이므로 모델의 예측력을 위해 제거하지 않고 그대로 사용. (단, 스케일링을 통해 영향력을 조절)"



모델링 및 기대 효과

- 사용 모델
 - 로지스틱 회귀 (Logistic Regression)
 - 의사결정나무 (Decision Tree)
 - 랜덤 포레스트 (Random Forest)
- 예측 내용 및 기대 효과
 - '고가 주택' 여부를 분류하는 예측 모델을 구축
 - 랜덤 포레스트의 변수 중요도 (Feature Importance)를 분석
 - area와 airconditioning, parking 등의 중요도를 비교하여, '고가 주택' 분류에 가장 결정적인 요인이 무엇인지에 대한 결과를 도출 (대립가설 검증).

모델링 및 기대 효과

- 기대 효과
 - "면적이 넓으면 비싸다"는 단편적인 상식을 넘어, 고가 주택을 결정짓는 요인들의 복합적인 우선순위를 데이터에 기반하여 수치적으로 증명
 - 주택 구매자, 판매자, 혹은 부동산 개발업자에게 어떤 요소에 투자하는 것이 주택의 가치를 높이는 데 가장 효율적인지에 대한 데이터 기반 의사결정 근거 제공
 - 완성된 모델로 새로운 주택 매물의 특징(면적, 에어컨 유무, 주차공간 등)을 입력했을 때, 해당 매물이 '고가'로 분류될지 '저가'로 분류될지 예측, 객관적인 가격 책정이나 매물 가치 평가의 보조 도구로 활용

감사합니다

