
통신사 고객 이탈 예측 모델 결과 보고서

요금인가, 서비스인가?

20215235 전승혁

20227122 윤태근

목차

01. 서론

02. 데이터 전처리

03. 데이터 시각화

04. 가설 수립

05. 모델링 및 분석

06. 결론 및 시사점

추가

발표 이후 교수님의 피드백을 적극적으로 수용하여 추가한 내용입니다.

- 그래프를 더 다양하게 활용하여 데이터 이해도 제고 필요 :
 - 상관관계 히트맵 및 밀도 플롯 추가
- 데이터 불균형 문제 해결 시도 :
 - Down-Sampling(50:50) 적용 및 성능 비교

주제 선정 및 데이터 개요




- 주제 : 통신사 고객 이탈(Churn) 데이터 분석
- 선정 배경: 단순한 요금 문제인지, 서비스/계약 구조 의 문제인지 데이터로 규명
- 데이터셋: Kaggle 'Telco Customer Churn' (7,043행, 21개 변수)
- 변수 구성:
 - 반응 변수: Churn (이탈 여부: Yes/No)
 - 설명 변수: tenure(가입 기간), MonthlyCharges(월 요금), Contract(계약 형태) 등

head(telco_raw)

A tibble: 6 × 21														
customerID	gender	SeniorCitizen	Partner	Dependents	tenure	PhoneService	MultipleLines	InternetService	OnlineSecurity	...	DeviceProtection	TechSupport	StreamingTV	Stre
<chr>	<chr>	<int>	<chr>	<chr>	<int>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>
7590-VHVEG	Female	0	Yes	No	1	No	No phone service	DSL	No	...	No	No	No	
5575-GNVDE	Male	0	No	No	34	Yes	No	DSL	Yes	...	Yes	No	No	
3668-QPYBK	Male	0	No	No	2	Yes	No	DSL	Yes	...	No	No	No	
7795-CFOCW	Male	0	No	No	45	No	No phone service	DSL	Yes	...	Yes	Yes	No	
9237-HQITU	Female	0	No	No	2	Yes	No	Fiber optic	No	...	No	No	No	
9305-CDSKC	Female	0	No	No	8	Yes	Yes	Fiber optic	No	...	Yes	No	Yes	

데이터 시각화

- 분석 대상:
 - 수치형 핵심 변수 3종: tenure(가입 기간), MonthlyCharges(월 요금), TotalCharges(총 요금)
- 시각화 도구:
 - Boxplot : 데이터의 분포와 이상치를 확인하기 위해 사용.
- 분석 결과 :
 - 통계적으로 유의미한 이상값 미발견
 - 데이터가 전반적으로 고르게 분포되어 있어, 별도의 이상치 제거 없이 모델링 진행.



데이터 전처리

- 불필요 변수 제거: 분석에 영향이 없는 단순 식별자 customerID 삭제
- 범주형 변수 변환 :
 - 모든 문자열(Character) 변수를 Factor 타입으로 변환
 - 목적: 분류 모델이 범주형 데이터를 올바르게 학습할 수 있도록 포맷 통일
- 결측치(NA) 처리: TotalCharges 변수 내 11개 결측값 발견
 - 기존 청구 금액을 0으로 대체했으나, 통계적 적합성을 위해 결측값이 포함된 행을 제거

3. 데이터 가공 (변수 제거)

```
telco <- telco_raw %>% select(-customerID)
telco <- telco %>% mutate_if(is.character, as.factor)
str(telco$Churn)

Factor w/ 2 levels "No","Yes": 1 1 2 1 2 2 1 1 2 1 ...
```

4. NA 처리 (TotalCharges 공백 처리)

```
# telco$TotalCharges[is.na(telco$TotalCharges)] <- 0
# 통계적 적합성을 위해 결측값이 포함된 행을 제거
telco <- na.omit(telco)

# 확인
table(is.na(telco))

FALSE
140640
```

데이터 전처리

- 기존 설명변수 19개를 모두 사용하는 과정에서 다중공선성 문제 방지를 위해 TotalCharges 변수는 로지스틱 회귀 모델링 단계에서 제외

로지스틱 회귀 모델 생성

```
# TotalCharges는 MonthlyCharges * tenure와 강한 상관관계가 있어 다중공선성을 유발, 제외(-TotalCharges)  
lorm_telco <- glm(Churn ~ . -TotalCharges, family = "binomial", data = train_telco)
```

추가 : 변수 간 상관관계 분석





Correlation Matrix of Numeric Variables

- 해석:
 - TotalCharges와 tenure의 상관관계수가 매우 높음(0.82 이상)을 확인.
 - 이는 총 요금이 가입 기간을 대변한다는 강력한 증거



추가 : 타겟 변수 심층 시각화

- 해석:
 - 밀도 그래프 (Density Plot):
 - 이탈한 사람들의 분포 비교
 - 요금이 높은 곳에 쏠려있는 것을 확인
 - 누적 막대 그래프
 - 무약정 고객에서 이탈 비율이 높은 것을 확인



데이터 가공

- 가공 목적
 - tenure(개월 수)와 MonthlyCharges(금액) 등 수치형 변수 간의 값의 범위(Scale) 차이가 큼
 - 그대로 학습 시, 숫자가 큰 변수(TotalCharges)에 가중치가 쏠리는 왜곡 방지
- 수행 방법:
 - 표준화 (Standardization): scale() 함수를 사용하여 평균 0, 표준편차 1인 분포로 변환
 - 대상 변수: tenure, MonthlyCharges, TotalCharges (3개 변수)

5. 데이터 스케일링

```
telco$tenure <- as.numeric(scale(telco$tenure))  
telco$MonthlyCharges <- as.numeric(scale(telco$MonthlyCharges))  
telco$TotalCharges <- as.numeric(scale(telco$TotalCharges))
```

연구 가설 수립

- 연구 질문 :
 - 고객 이탈(Churn)을 결정하는 핵심 요인은 무엇인가?
 - (단순한 '요금(Cost)' 문제인가? vs '계약 구조(Structure)'의 문제인가?)
- 가설 설정:
 - 귀무가설 (H0): 고객 이탈에 가장 큰 영향을 주는 요인은 월 요금(MonthlyCharges)과 같은 비용적 요소이다
 - 대립가설 (H1): 비용보다는 계약 형태(Contract)나 가입 기간(tenure)등 구조적 요인이 더 결정적이다
- 검증 방법:
 - 랜덤 포레스트(Random Forest) 모델의 변수 중요도 분석을 통해 검증 예정
 - 카이제곱 검정 수행

분석 모델 설계

- 데이터 분할 :
 - 비율: 학습용(Train) 75% : 평가용(Test) 25%
 - 목적: 모델의 과적합(Overfitting) 방지 및 일반화 성능 검증.
- 사용 알고리즘 :
 - 로지스틱 회귀 (Logistic Regression)
 - 의사결정나무 (Decision Tree)
 - 랜덤 포레스트 (Random Forest)

데이터 분할 (Train / Test)

```
# Churn 변수 Factor 변환
telco$Churn <- as.factor(telco$Churn)

set.seed(42)
train_idx <- createDataPartition(telco$Churn, p = 0.75, list = FALSE)

train_telco_raw <- telco[train_idx, ]
test_telco_raw <- telco[-train_idx, ]

preprocess_model <- preProcess(train_telco_raw, method = c("center", "scale"))

train_telco <- predict(preprocess_model, train_telco_raw)
test_telco <- predict(preprocess_model, test_telco_raw)
```

분석 모델 설계 : EDA 및 통계 검정

- 분석 개요
 - 목적: 이탈 여부(Churn)와 계약 형태(Contract) 간의 통계적 연관성 검증
 - 방법: 카이제곱 검정 (Chi-square Test)
- 검정 결과
 - Chi-square 값: 1179.546
 - P-value: 7.32e-257 (< 0.05)

```
CrossTable(telco$Churn, telco$Contract, chisq = TRUE)
```

Cell Contents
N
Chi-square contribution
N / Row Total
N / Col Total
N / Table Total

Total Observations in Table: 7032

	telco\$Contract			
telco\$Churn	Month-to-month	One year	Two year	Row Total
No	2220	1306	1637	5163
	137.335	46.940	129.231	
	0.430	0.253	0.317	0.734
	0.573	0.887	0.972	
	0.316	0.186	0.233	
Yes	1655	166	48	1869
	379.379	129.669	356.992	
	0.886	0.089	0.026	0.266
	0.427	0.113	0.028	
	0.235	0.024	0.007	
Column Total	3875	1472	1685	7032
	0.551	0.209	0.240	


Statistics for All Table Factors

Pearson's Chi-squared test

Chi^2 = 1179.546 d.f. = 2 p = 7.326182e-257

모델 성능 평가

- 평가 지표:
 - ROC Curve & AUC: 데이터 불균형을 고려하여 모델의 변별력 확인
- 최적 Cut-off 도출 :
 - 민감도와 특이도를 고려한 최적의 임계값 설정
 - (약 0.56)



모델 성능 평가

- 로지스틱회귀
 - Accuracy: 80.08% (1위)
 - Balanced Accuracy : 69.15%
- 해석력 우수, 가설 검증용

[1] "로지스틱 회귀 성능 평가"
Confusion Matrix and Statistics

	Reference	
Prediction	No	Yes
No	1193	253
Yes	97	214

Accuracy : 0.8008

95% CI : (0.7813, 0.8192)

No Information Rate : 0.7342

P-Value [Acc > NIR] : 4.581e-11

Kappa : 0.4287

McNemar's Test P-Value : < 2.2e-16

Sensitivity : 0.4582

Specificity : 0.9248

Pos Pred Value : 0.6881

Neg Pred Value : 0.8250

Prevalence : 0.2658

Detection Rate : 0.1218

Detection Prevalence : 0.1770

Balanced Accuracy : 0.6915

'Positive' Class : Yes

모델 성능 평가

- 의사결정나무
 - Accuracy: 78.37%
 - Balanced Accuracy : 64.44%
- 시각화 용이, 성능은 다소 낮음

[1] "의사결정나무 성능 평가"
Confusion Matrix and Statistics

	Reference	
Prediction	No	Yes
No	1215	305
Yes	75	162


Accuracy : 0.7837
95% CI : (0.7637, 0.8028)
No Information Rate : 0.7342
P-Value [Acc > NIR] : 9.245e-07

Kappa : 0.3426

McNemar's Test P-Value : < 2.2e-16

Sensitivity : 0.3469
Specificity : 0.9419
Pos Pred Value : 0.6835
Neg Pred Value : 0.7993
Prevalence : 0.2658
Detection Rate : 0.0922
Detection Prevalence : 0.1349
Balanced Accuracy : 0.6444

'Positive' Class : Yes



모델 성능 평가

- 랜덤포레스트
 - Accuracy: 79.80%
 - Balanced Accuracy : 69.37% (1위)
- 실질적 예측 성능 최우수

[1] "랜덤 포레스트 성능 평가"
Confusion Matrix and Statistics


Reference		
Prediction	No	Yes
No	1177	248
Yes	113	219
Accuracy : 0.7945		
95% CI : (0.7749, 0.8132)		
No Information Rate : 0.7342		
P-Value [Acc > NIR] : 2.472e-09		
Kappa : 0.4201		
McNemar's Test P-Value : 1.756e-12		
Sensitivity : 0.4690		
Specificity : 0.9124		
Pos Pred Value : 0.6596		
Neg Pred Value : 0.8260		
Prevalence : 0.2658		
Detection Rate : 0.1246		
Detection Prevalence : 0.1890		
Balanced Accuracy : 0.6907		
'Positive' Class : Yes		

결론 및 시사점 : 변수 중요도 시각화

시각화

```
ggplot(top_features, aes(x = reorder(Feature, MeanDecreaseGini), y = MeanDecreaseGini)) +  
  geom_bar(stat = "identity", fill = "steelblue") +  
  coord_flip() +  
  labs(title = "Top 10 Feature Importances (Random Forest)",  
        x = "Features", y = "Importance") +  
  theme_minimal()
```

- TotalCharges (총 요금) [1위]
- tenure (가입 기간)
- MonthlyCharges (월 요금)
- Contract (계약 형태)
- PaymentMethod (지불 방식)
- OnlineSecurity (온라인 보안)
- InternetService (인터넷 서비스 종류)
- TechSupport (기술 지원)
- OnlineBackup (전자 청구서 여부)
- Gender [10위]



결론 및 시사점 : 변수 중요도 분석

- 분석 도구 :
 - 랜덤 포레스트(Random Forest)의 변수 중요도(Variable Importance)
- 상위 3대 요인:
 - TotalCharges (총 요금): '월 요금 × 가입 기간'의 누적값이므로 '장기 가입'의 특성이 강하게 반영됨.
 - tenure (가입 기간) : 순수한 기간 변수. 가입 기간이 길어질수록 이탈률이 낮아지는 강력한 상관관계 확인.
 - MonthlyCharges (월 요금) : 순수 비용 변수.


```
lorm_bw_telco <- step(lorm_telco, direction = "backward", trace = 0)  
summary(lorm_bw_telco)
```

```
tenure          -0.88284    0.06362 -13.876  < 2e-16 ***
```

- 결론 :
 - 변수 중요도 1, 2위가 모두 시간과 밀접하게 연관됨.
 - 고객은 요금보다 서비스 이용 기간과 계약 관계(Retention)에 의해 이탈을 결정함

결론 및 시사점 : 가설 해석

- 변수 해석의 주의점:
 - 변수 중요도 1위인(TotalCharges)는 Tenure와 강한 양의 상관관계를 가지므로, 단순 비용 불만이 아닌 장기 고객 특성으로 해석됨
 - $\text{TotalCharges} = \text{MonthlyCharges} * \text{tenure}$
- 종합 :
 - 고객 이탈의 본질적인 핵심 요인은 단순 비용보다는 가입 기간(tenure)에 따른 충성도와 계약 구조(Contract)로 확인할 수 있음



결론 및 시사점 : 통계적 유의성 확인

- 분석 도구 :
 - 카이제곱 검정 (Chi-square Test) 수행
- 검정 결과:
 - p-value: $< 2.2e-16$ (0.05 미만)
 - 해석: 귀무가설 기각, 대립가설 채택.
 - "계약 형태에 따라 이탈률에 유의미한 차이가 존재함"을 통계적으로 입증.
- 결론: 머신러닝 모델(Random Forest)의 변수 중요도 결과와 통계적 검정 결과가 일치함.

결론 및 시사점 : 가설 검증

- 검증 1 :
 - 통계적 유의성 검정 (카이제곱)분석: 이탈 여부(Churn) vs 계약 형태(Contract)
 - 결과: $p\text{-value} < 0.05$ ($2.2e-16$) 로 통계적으로 매우 유의함.
 - 의미: 계약 형태에 따라 이탈률에 차이가 있음을 입증.
- 검증 2 :
 - 머신러닝 변수 중요도 (Random Forest)분석:
 - tenure(가입 기간), TotalCharges(총 요금), Contract(계약 형태)가 최상위권 형성.

결론 및 시사점 : 가설 검증 및 결론

- 가설 검증 :

- 귀무가설(H0) 기각: 고객은 단순히 월 요금이 높다고 이탈하지 않음.
- 대립가설(H1) 채택: 고객의 이탈 여부는 서비스 이용 기간과 계약의 구속력에 의해 결정

- 최종 결론:

고객은 '단순 비용(Cost)' 때문에 이탈하는 것이 아니라,
'서비스 이용 기간'과 '계약 구조의 구속력'이 더 결정적인 요인임을 알 수 있다.

결론 및 시사점 : 비즈니스 전략 제안

- 장기 약정 유도 전략:
단기(Month-to-month) 가입자에게 '1년/2년 약정' 전환 시 파격적인 혜택 제공.
- 신규 고객 집중 케어:
이탈 위험이 가장 높은 '가입 초기(tenure 낮음)' 고객을 위한 서비스 강화.
- 결합 상품 활성화:
인터넷, 보안 등 부가 서비스(InternetService 등) 가입을 유도하여 전환 장벽 높이기.

추가 : 데이터 불균형 처리

- 밸런싱된 데이터로 랜덤 포레스트 모델 재학습 :
 - 데이터 불균형을 다운샘플링으로 해결해 이탈과 잔존의 비율을 50:50으로 맞춰 해결.

```
# 기존 Train 데이터를 사용하여 다운 샘플링을 실행하고 비율을 1:1로 맞춰 성능확인
set.seed(42)
train_balanced <- downSample(x = train_telco[, -which(names(train_telco) == "Churn")],
                             y = train_telco$Churn)
names(train_balanced)[names(train_balanced) == "Class"] <- "Churn"

# 균형 확인
print("샘플링 전 Train 데이터 비율 ")
print(table(train_telco$Churn))
print("샘플링 후 Train 데이터 비율")
print(table(train_balanced$Churn))

# 랜덤 포레스트 모델 재학습
set.seed(42)
rf_model_balanced <- randomForest(Churn ~ .,
                                  data = train_balanced,
                                  importance = TRUE,
                                  ntree = 100)

# 예측 수행 (현실 반영을 위해 test 데이터는 그대로 사용하였습니다!)
rf_pred_balanced <- predict(rf_model_balanced, newdata = test_telco)

# 성능 비교 평가
print("랜덤 포레스트 (불균형 데이터 학습) ")
confusionMatrix(rf_pred, test_telco$Churn, positive = "Yes")

print("랜덤 포레스트 (50:50 데이터 학습)")
confusionMatrix(rf_pred_balanced, test_telco$Churn, positive = "Yes")
```

추가 : 처리결과

- 민감도(Sensitivity) 급상승:
 - 기존 46.9%에서 76.8%로 약 30%증가
 - 이탈 고객을 놓치지 않고 잘 잡아냄
- 균형 정확도(Balanced Accuracy) 개선:
 - 69.1%에서 76.1%로 증가
 - 특정 클래스에 치우치지 않는 안정적인 성능 확보
- Trade-off:
 - 특이도(Specificity)가 감소
 - 정확도(Accuracy):
 - 79.5% 에서 75.7%로 소폭 하락함

[1] "샘플링 전 Train 데이터 비율 "

	No	Yes
	3873	1402

[1] "랜덤 포레스트 (불균형 데이터 학습) "
Confusion Matrix and Statistics

	Reference	
Prediction	No	Yes
No	1177	248
Yes	113	219

Accuracy : 0.7945

95% CI : (0.7749, 0.8132)

No Information Rate : 0.7342

P-Value [Acc > NIR] : 2.472e-09

Kappa : 0.4201

Mcnemar's Test P-Value : 1.756e-12

Sensitivity : 0.4690

Specificity : 0.9124

Pos Pred Value : 0.6596

Neg Pred Value : 0.8260

Prevalence : 0.2658

Detection Rate : 0.1246

Detection Prevalence : 0.1890

Balanced Accuracy : 0.6907

'Positive' Class : Yes

[1] "샘플링 후 Train 데이터 비율"

	No	Yes
	1402	1402

[1] "랜덤 포레스트 (50:50 데이터 학습)"
Confusion Matrix and Statistics

	Reference	
Prediction	No	Yes
No	971	108
Yes	319	359

Accuracy : 0.757

95% CI : (0.7362, 0.7769)

No Information Rate : 0.7342

P-Value [Acc > NIR] : 0.01582

Kappa : 0.4558

Mcnemar's Test P-Value : < 2e-16

Sensitivity : 0.7687

Specificity : 0.7527

Pos Pred Value : 0.5295

Neg Pred Value : 0.8999

Prevalence : 0.2658

Detection Rate : 0.2043

Detection Prevalence : 0.3859

Balanced Accuracy : 0.7607

'Positive' Class : Yes

추가 : 결론

- 비즈니스 목표인 이탈 방어를 위해서는
이탈자 탐지율이 높은 50:50 샘플링 적용 모델이 더 적합하다는 것을 알 수 있음.

감사합니다

